**FAESA — CENTRO UNIVERSITÁRIO**
**CURSOS DE SISTEMAS DE INFORMAÇÃO E CIÊNCIA DA COMPUTAÇÃO**

https://github.com/JulianoDADR/FAESA-Projeto-Integrador-IV

**CAUAN HENRIQUE DAMASCENA GOMES**
**EDUARDO RODRIGUES RANGEL MALAQUIAS**
**GUILHERME DE SOUZA PAIVA**
**JULIANO DE ANDRADE DANTAS RODRIGUES**
**RUBIALE ALVES DE MELO FILHO**

# AGROANÁLISE

## INCLUSÃO DIGITAL NO CAMPO COM INTERNET DAS COISAS (IoT) E MACHINE LEARNING

Projeto Integrador IV — 2026/2
Professor: Prof. M.Sc. Howard Cruz Roatti

Vitória/ES
2026

**CAUAN HENRIQUE DAMASCENA GOMES**
**EDUARDO RODRIGUES RANGEL MALAQUIAS**
**GUILHERME DE SOUZA PAIVA**
**JULIANO DE ANDRADE DANTAS RODRIGUES**
**RUBIALE ALVES DE MELO FILHO**

# AGROANÁLISE

## INCLUSÃO DIGITAL NO CAMPO COM INTERNET DAS COISAS (IoT) E MACHINE LEARNING

Relatório apresentado à disciplina Projeto Integrador IV, dos cursos de Sistemas de Informação e Ciência da Computação da FAESA — Centro Universitário, como parte das atividades avaliativas do semestre 2026/2.

Professor: Prof. M.Sc. Howard Cruz Roatti.

Vitória/ES
2026

**SUMÁRIO**

1 INTRODUÇÃO
2 CONTEXTUALIZAÇÃO DO PROBLEMA
3 JUSTIFICATIVA
4 OBJETIVOS
4.1 Objetivo geral
4.2 Objetivos específicos
5 FUNDAMENTAÇÃO TEÓRICA
5.1 Agricultura familiar e inclusão digital
5.2 Cafeicultura e variáveis ambientais
5.3 Internet das Coisas e sensores
5.4 Processamento de dados e armazenamento
5.5 Aprendizado de máquina e classificação
5.6 Avaliação de modelos de classificação
6 ESCOPO E REQUISITOS DO PROJETO
6.1 Público-alvo e cultura inicial
6.2 Regras de negócio e funcionalidades
6.3 Limites do MVP
7 METODOLOGIA
7.1 Natureza e abordagem
7.2 Levantamento e curadoria dos dados
7.3 Coleta e tratamento dos dados
7.4 Treinamento e avaliação do modelo
7.5 Desenvolvimento da interface
7.6 Testes de software
8 DESCRIÇÃO DA SOLUÇÃO PROPOSTA
8.1 Arquitetura geral
8.2 Fluxo operacional
8.3 Semáforo virtual
9 COMUNIDADE IMPACTADA E INDICADORES
10 IA RESPONSÁVEL, RISCOS E LIMITAÇÕES
11 PLANO DE TRABALHO
12 RESULTADOS ESPERADOS
13 CONSIDERAÇÕES FINAIS

## 1 INTRODUÇÃO

A agricultura desempenha papel relevante na organização econômica e social de diferentes regiões brasileiras, especialmente em comunidades nas quais a produção rural constitui uma das principais fontes de renda e sustento familiar. Nesse contexto, o acesso a informações sobre as condições do ambiente e do solo pode contribuir para decisões mais conscientes relacionadas ao manejo das lavouras. Entretanto, a obtenção, a interpretação e o uso dessas informações nem sempre são simples, sobretudo quando o produtor dispõe de poucos recursos tecnológicos ou apresenta baixo nível de letramento digital.

O avanço de tecnologias como a Internet das Coisas (Internet of Things — IoT) e o aprendizado de máquina (Machine Learning — ML) permite desenvolver sistemas capazes de coletar variáveis ambientais, processar dados e identificar padrões que auxiliem atividades produtivas. Sensores conectados a microcontroladores podem realizar medições em campo, enquanto aplicações computacionais organizam essas informações e produzem classificações que apoiam a interpretação dos dados.

É nesse cenário que se insere o projeto AgroAnálise, uma proposta de solução tecnológica voltada à inclusão digital no campo. O projeto prevê o desenvolvimento de um sistema de monitoramento de plantações de café, inicialmente contemplando as espécies Arábica e Conilon, com coleta de umidade do solo, temperatura do ambiente e umidade relativa do ar. As informações serão encaminhadas a uma aplicação desenvolvida em Python, tratadas e armazenadas em banco de dados, e posteriormente utilizadas por um modelo de classificação baseado em Machine Learning.

O resultado da análise será apresentado por meio de uma interface visual simplificada, organizada como um semáforo: verde para condição considerada ideal, amarelo para situação de atenção e vermelho para condição crítica que demande verificação ou ação do produtor. A escolha desse formato busca reduzir a complexidade da informação apresentada, evitando que a utilização do sistema dependa da interpretação de gráficos ou indicadores técnicos.

Este relatório apresenta a concepção do AgroAnálise, sua relevância social e tecnológica, os objetivos, a fundamentação teórica, a metodologia de desenvolvimento,

a arquitetura planejada, os indicadores de impacto e o cronograma de execução. O documento considera as orientações do Projeto Integrador IV, que exige uma aplicação funcional, componente de inteligência artificial, testes de software, avaliação do modelo, atenção à responsabilidade tecnológica e análise da comunidade impactada.

## 2 CONTEXTUALIZAÇÃO DO PROBLEMA

A tomada de decisão no manejo agrícola depende da observação de diferentes condições que influenciam o desenvolvimento das plantas. No cultivo do café, a disponibilidade de água no solo e as condições térmicas do ambiente são fatores relevantes, mas sua interpretação exige considerar a espécie cultivada, as características do solo, o estágio da cultura, o clima local e as práticas de manejo adotadas.

Quando o acompanhamento dessas condições ocorre apenas por observação visual ou por avaliações realizadas em intervalos longos, alterações ambientais podem não ser percebidas no momento mais adequado. A ausência de informação organizada também pode dificultar a identificação de situações de déficit hídrico ou de condições ambientais desfavoráveis. Como consequência, decisões de irrigação podem ser tomadas sem apoio suficiente de dados, o que pode contribuir tanto para o uso inadequado da água quanto para a exposição da lavoura a situações de estresse.

O problema apresenta uma dimensão adicional quando considerado o público da agricultura familiar com baixo ou nenhum letramento digital. Mesmo quando existem dados ou ferramentas de monitoramento disponíveis, a complexidade das interfaces, dos gráficos e da linguagem técnica pode limitar sua utilização autônoma. Assim, a dificuldade não está apenas em coletar informações, mas também em transformá-las em orientações compreensíveis e úteis para quem realiza o manejo da propriedade.

O AgroAnálise procura enfrentar essas duas dimensões de forma integrada: de um lado, automatizar a coleta e o processamento de variáveis ambientais; de outro, simplificar a apresentação do resultado. O sistema não pretende substituir o conhecimento do agricultor, a assistência técnica ou a avaliação agronômica. Sua função é oferecer uma indicação preliminar, baseada nas variáveis monitoradas e nos

critérios definidos para o projeto, que facilite a percepção de situações que mereçam atenção.

O recorte inicial será a cafeicultura, contemplando Café Arábica (Coffea arabica) e Café Conilon ou Canéfora (Coffea canephora). A escolha considera a importância da cultura no contexto regional e a possibilidade de estabelecer parâmetros de referência específicos para cada espécie. A literatura técnica destaca que o manejo da água é relevante para a produção de Conilon em regiões capixabas, nas quais a distribuição das chuvas pode ser irregular (BONOMO et al., 2014).

## 3 JUSTIFICATIVA

A relevância do AgroAnálise está na combinação entre monitoramento ambiental, análise computacional e acessibilidade da informação. Em vez de disponibilizar ao produtor um conjunto de números cuja interpretação exige conhecimento técnico, a proposta transforma as leituras dos sensores em uma classificação visual direta. Dessa maneira, a tecnologia é planejada não apenas para coletar dados, mas para aproximar a informação técnica da rotina de quem trabalha no campo.

Do ponto de vista social, o projeto relaciona-se à inclusão digital de agricultores familiares. A simplificação da interface procura diminuir barreiras de utilização e favorecer a autonomia do usuário, especialmente daqueles que não possuem familiaridade com ferramentas digitais complexas. A adoção de uma representação semelhante a um semáforo aproveita um código visual amplamente reconhecível e reduz a necessidade de leitura de tabelas ou gráficos.

Sob a perspectiva econômica e ambiental, o acompanhamento mais frequente da umidade do solo pode apoiar decisões de irrigação mais criteriosas. O uso racional da água é uma questão importante no manejo agrícola, mas não se deve presumir que a instalação do sistema produzirá automaticamente economia ou aumento de produtividade. Esses efeitos deverão ser investigados por meio de indicadores e, quando possível, comparações entre condições de uso e períodos de referência.

A justificativa técnica decorre da integração de componentes de hardware e software em uma arquitetura acessível para prototipagem. O Arduino realizará a leitura dos sensores; a comunicação serial permitirá transferir os dados ao Python; bibliotecas

de processamento auxiliarão na organização e no tratamento das leituras; o SQLite armazenará o histórico; e o Scikit-Learn será utilizado na construção e avaliação do classificador. Essa composição permite demonstrar, em escala de protótipo, a integração entre IoT e Machine Learning.

Por fim, o projeto possui aderência aos objetivos do Projeto Integrador IV por propor uma aplicação tecnológica funcional, orientada a um problema concreto, com comunidade impactada identificável, componente de IA, avaliação quantitativa, testes de software e reflexão sobre os riscos e limites da solução.

# 4 OBJETIVOS

## 4.1 Objetivo geral

Desenvolver uma solução de monitoramento agrícola baseada em IoT e Machine Learning, capaz de coletar e processar dados de umidade do solo, temperatura ambiente e umidade relativa do ar em plantações de café, classificando as condições monitoradas em níveis de risco apresentados por uma interface visual simplificada, com o propósito de apoiar a tomada de decisão e promover a inclusão digital de agricultores familiares.

## 4.2 Objetivos específicos

1. Identificar parâmetros agronômicos e ambientais de referência para o cultivo de Café Arábica e Conilon, considerando fontes técnicas reconhecidas e as particularidades de cada espécie.
2. Construir um protótipo de coleta de dados utilizando microcontrolador Arduino, sensor de umidade do solo e sensor DHT11 para temperatura e umidade relativa do ar.
3. Implementar a comunicação entre o microcontrolador e a aplicação Python por meio da biblioteca PySerial.
4. Desenvolver rotinas de tratamento, organização e armazenamento das leituras, utilizando Pandas, NumPy e banco de dados SQLite.
5. Preparar um conjunto de dados histórico e/ou simulado, com critérios documentados para a definição das classes de condição da lavoura.

6. Treinar um modelo de classificação com Scikit-Learn para categorizar as condições monitoradas em Verde, Amarelo e Vermelho.
7. Avaliar o desempenho do classificador por meio de matriz de confusão, precisão, revocação, F1-Score e acurácia, analisando especialmente os erros que possam levar a decisões inadequadas.
8. Desenvolver uma interface visual acessível, com linguagem simples e sinalização por cores, reduzindo a dependência de gráficos complexos.
9. Executar testes unitários, de integração e de ponta a ponta para verificar a comunicação entre sensores, processamento, modelo e interface.
10. Definir indicadores que permitam acompanhar a adoção autônoma, a eficiência hídrica estimada e a ocorrência de perdas associadas à identificação tardia de estresse hídrico ou térmico.

# 5 FUNDAMENTAÇÃO TEÓRICA

## 5.1 Agricultura familiar e inclusão digital

A transformação digital no meio rural depende não apenas da disponibilidade de equipamentos e conectividade, mas também da capacidade dos usuários de compreender e incorporar as ferramentas às suas atividades. Uma solução pode apresentar recursos tecnicamente avançados e, ainda assim, ter baixa utilidade prática se sua interface exigir conhecimentos incompatíveis com o perfil do público pretendido.

No AgroAnálise, a inclusão digital é tratada como requisito de projeto. A aplicação deverá priorizar informações essenciais, textos objetivos, elementos visuais de fácil identificação e uma organização que permita compreender a condição monitorada sem exigir interpretação de séries numéricas. O semáforo virtual é o principal recurso de mediação entre o processamento técnico e a experiência do produtor.

A autonomia de uso também será considerada um resultado relevante. Por isso, o projeto prevê acompanhar quantas propriedades ou usuários conseguem operar o protótipo sem suporte técnico contínuo. Esse indicador permite avaliar se a simplificação da interface efetivamente contribui para a apropriação da tecnologia, em vez de medir somente o funcionamento técnico do sistema.

## 5.2 Cafeicultura e variáveis ambientais

O café é uma cultura perene cuja resposta às condições ambientais depende de fatores inter-relacionados. A temperatura, a disponibilidade hídrica, a umidade do solo, as características físicas e químicas do solo e o estágio de desenvolvimento da planta precisam ser considerados conjuntamente. Por esse motivo, não é adequado estabelecer um único limite universal de temperatura ou umidade que represente, isoladamente, a condição de todas as lavouras.

A base EcoCrop, desenvolvida pela Organização das Nações Unidas para a Alimentação e a Agricultura (FAO), reúne informações ambientais e características de diferentes espécies vegetais. Para Coffea arabica, a ficha consultada apresenta faixas de temperatura e precipitação de referência, além de características relacionadas ao solo. Esses valores constituem referências gerais e não devem ser convertidos diretamente em limites operacionais do protótipo sem validação para a região, cultivar e condições de manejo consideradas (FAO, s.d.).

No caso do Conilon, a Embrapa registra a importância do manejo da água em cultivos irrigados no Norte do Espírito Santo. Bonomo et al. (2014) avaliaram métodos de manejo da irrigação em cafeeiros Conilon adultos na região de São Mateus e observaram diferenças entre estratégias quanto à produtividade e ao consumo de água. Esse tipo de estudo reforça que a recomendação de irrigação deve considerar o contexto de produção e não apenas uma leitura isolada do sensor.

O projeto trabalhará inicialmente com três variáveis: umidade do solo, temperatura do ambiente e umidade relativa do ar. A umidade do solo oferece uma indicação direta da condição hídrica próxima ao ponto de instalação do sensor. A temperatura e a umidade relativa do ar contribuem para caracterizar o ambiente no momento da medição. Em conjunto, essas variáveis podem alimentar uma classificação preliminar, desde que os critérios sejam definidos e validados com referências agronômicas.

O Zoneamento Agrícola de Risco Climático (ZARC), disponibilizado pelo Ministério da Agricultura e Pecuária, reúne notas técnicas específicas para culturas e espécies, incluindo Café Arábica e Café Canéfora. O ZARC é uma referência de gestão de risco climático e planejamento agrícola; portanto, seus parâmetros devem ser

utilizados como contexto técnico, e não confundidos com limites instantâneos de acionamento de irrigação (BRASIL, 2024).

### 5.3 Internet das Coisas e sensores

A Internet das Coisas caracteriza-se pela integração de objetos físicos capazes de coletar ou transmitir dados por meio de sistemas computacionais. Em aplicações agrícolas, sensores instalados no ambiente ou no solo permitem obter medições que podem ser encaminhadas a um dispositivo de processamento para armazenamento, análise e visualização.

No protótipo proposto, o Arduino será utilizado como unidade de aquisição. Um sensor de umidade do solo fornecerá leituras relacionadas à condição hídrica do substrato, enquanto o DHT11 realizará medições de temperatura e umidade relativa do ar. O microcontrolador organizará as leituras e as enviará ao computador por comunicação serial.

É importante considerar que sensores de baixo custo apresentam limitações de precisão, faixa operacional, estabilidade e dependência das condições de instalação. No caso do sensor de umidade do solo, a leitura pode variar conforme o tipo de solo, a compactação, a salinidade, a profundidade e o contato entre o sensor e o material. Assim, a conversão da leitura bruta em percentual ou faixa de umidade exige calibração. O protótipo deverá registrar as unidades, a frequência de amostragem e os procedimentos utilizados para verificar a consistência dos dados.

O DHT11 também possui limitações de resolução e faixa de medição. Sua utilização é adequada para demonstração e prototipagem, mas os resultados não devem ser apresentados como medições meteorológicas de precisão sem comparação com instrumentos de referência. Essas limitações serão consideradas na análise dos resultados e na descrição do alcance do MVP.

### 5.4 Processamento de dados e armazenamento

Após a aquisição, os dados serão recebidos por uma aplicação desenvolvida em Python. A biblioteca PySerial será utilizada para estabelecer a comunicação com a porta serial do microcontrolador. A aplicação deverá identificar leituras válidas,

interpretar os campos recebidos e registrar informações como data e hora, umidade do solo, temperatura e umidade relativa do ar.

O tratamento dos dados é necessário para reduzir problemas que possam comprometer a classificação. Entre as verificações previstas estão a identificação de valores ausentes, leituras fora de faixas fisicamente plausíveis, duplicidades, falhas de comunicação e oscilações abruptas. Pandas e NumPy apoiarão a manipulação dos dados, a organização das amostras e a execução de operações numéricas.

O armazenamento será realizado inicialmente em SQLite3, banco de dados relacional leve e adequado ao escopo de um protótipo local. O histórico permitirá consultar medições anteriores, compor conjuntos de dados para treinamento e avaliação e verificar a evolução das condições monitoradas. A estrutura deverá preservar a associação entre cada leitura, seu momento de coleta e, quando aplicável, a identificação do ponto de monitoramento.

### 5.5 Aprendizado de máquina e classificação

Machine Learning é uma área da inteligência artificial que desenvolve métodos capazes de identificar padrões em dados e produzir estimativas ou classificações a partir de exemplos. No AgroAnálise, será empregado um modelo de classificação supervisionada, cuja saída corresponderá a uma das três categorias definidas pelo projeto: Verde, Amarelo ou Vermelho.

A classificação será alimentada pelas variáveis coletadas pelos sensores. Para que o treinamento seja tecnicamente válido, cada amostra do conjunto de dados deverá possuir uma classe de referência (rótulo) definida por critérios documentados. Esses rótulos poderão ser construídos a partir de parâmetros agronômicos de referência, dados históricos e/ou simulações, conforme previsto no relatório inicial. A origem de cada amostra e o método de rotulagem deverão ser explicitados.

Há uma limitação metodológica importante quando os rótulos são gerados exclusivamente por regras fixas aplicadas às mesmas variáveis utilizadas como entrada. Nesse cenário, o modelo pode aprender a reproduzir as regras que geraram os rótulos, sem necessariamente demonstrar capacidade de antecipar o estresse real da planta. Por isso, o desempenho obtido em dados simulados deverá ser interpretado

como uma validação inicial do pipeline de classificação, e não como comprovação de eficácia agronômica em campo.

A separação entre treinamento e teste será inicialmente realizada na proporção de 80% e 20%, conforme planejado no relatório do projeto. Sempre que a quantidade e a distribuição dos dados permitirem, recomenda-se utilizar divisão estratificada para preservar a proporção das classes. Também será necessário evitar que registros muito semelhantes ou provenientes da mesma sequência temporal apareçam simultaneamente nos conjuntos de treinamento e teste, pois isso pode produzir estimativas excessivamente otimistas.

### 5.6 Avaliação de modelos de classificação

A avaliação do classificador será realizada por métricas complementares. A acurácia representa a proporção total de previsões corretas, mas pode ser insuficiente quando as classes possuem frequências diferentes ou quando determinados erros têm consequências mais graves. Por isso, o projeto também utilizará precisão, revocação, F1-Score e matriz de confusão, métricas disponíveis no módulo de avaliação do Scikit-Learn (SCIKIT-LEARN, s.d.).

A precisão indica, para uma classe, a proporção de previsões daquela classe que estavam corretas. A revocação indica a proporção de exemplos reais daquela classe que foram identificados pelo modelo. O F1-Score combina precisão e revocação por meio de média harmônica. A matriz de confusão permite observar quais classes estão sendo confundidas, identificando, por exemplo, casos em que uma condição crítica foi classificada como atenção ou ideal.

No contexto agrícola, a interpretação dos erros deve considerar suas consequências. Um falso alerta de necessidade de irrigação pode contribuir para desperdício de água; por outro lado, deixar de sinalizar uma condição de risco pode atrasar a avaliação do produtor. A avaliação deverá, portanto, analisar os erros por classe e não apenas apresentar um valor global de acurácia.

# 6 ESCOPO E REQUISITOS DO PROJETO

## 6.1 Público-alvo e cultura inicial

O público-alvo do AgroAnálise é formado por agricultores familiares que apresentam baixo ou nenhum letramento digital. A cultura inicial será o café, abrangendo Arábica e Conilon. A escolha permite delimitar o escopo e concentrar o levantamento de parâmetros em uma cultura de relevância para a região, sem impedir que futuras versões sejam adaptadas a outras plantações.

## 6.2 Regras de negócio e funcionalidades

| Elemento | Definição do projeto |
|---|---|
| Público-alvo | Agricultores familiares com baixo ou nenhum letramento digital. |
| Cultura inicial | Café Arábica e Café Conilon. |
| Variáveis monitoradas | Umidade do solo, temperatura ambiente e umidade relativa do ar. |
| Aquisição | Arduino com sensor de umidade do solo e DHT11. |
| Processamento | Python, PySerial, Pandas e NumPy. |
| Armazenamento | Banco de dados relacional SQLite3. |
| Classificação | Modelo supervisionado desenvolvido com Scikit-Learn. |
| Saída ao usuário | Semáforo virtual: verde, amarelo e vermelho. |
| Avaliação | Matriz de confusão, precisão, revocação, F1-Score e acurácia. |

A aplicação deverá receber as leituras, verificar sua validade, armazená-las e encaminhá-las ao modelo de classificação. A interface apresentará o estado atribuído à leitura mais recente, acompanhado de uma mensagem curta que explique a condição sinalizada. Quando não houver leitura válida ou a comunicação com o sensor estiver indisponível, o sistema deverá informar que não há dados atualizados, evitando exibir uma cor que possa ser interpretada como avaliação válida.

## 6.3 Limites do MVP

O MVP estará concentrado no monitoramento das três variáveis descritas e na classificação em três estados. Não está previsto, no escopo inicial, controlar automaticamente bombas ou válvulas de irrigação, realizar diagnóstico de doenças,

estimar produtividade com precisão, substituir assistência técnica ou oferecer recomendação agronômica individualizada. A indicação visual será uma ferramenta de apoio e deverá deixar claro que a decisão de manejo continua sob responsabilidade do produtor, preferencialmente com orientação técnica quando necessária.

O projeto inicial também não define uma plataforma de nuvem, aplicativo móvel, conectividade de longo alcance ou instalação em múltiplas propriedades. Esses elementos poderão ser avaliados em evoluções futuras, mas não devem ser apresentados como funcionalidades já garantidas pelo MVP.

# 7 METODOLOGIA

## 7.1 Natureza e abordagem

O trabalho caracteriza-se como pesquisa aplicada, pois busca desenvolver uma solução tecnológica direcionada a um problema prático: a dificuldade de acompanhar variáveis ambientais e interpretar informações de manejo por parte de agricultores familiares com baixo letramento digital. A abordagem será predominantemente experimental e quantitativa na etapa de validação do sistema, complementada por análise qualitativa da facilidade de uso e da percepção dos usuários.

O desenvolvimento será iterativo e organizado conforme os checkpoints C1, C2 e C3 do Projeto Integrador IV. Cada etapa produzirá artefatos verificáveis, permitindo revisar decisões técnicas, identificar limitações e evoluir o protótipo até a entrega do MVP.

## 7.2 Levantamento e curadoria dos dados

O levantamento de parâmetros agronômicos será realizado a partir de fontes técnicas e bases de dados reconhecidas. O relatório inicial indica a utilização de EcoCrop/FAO e Kaggle para consulta e composição de dados, além de informações meteorológicas do INMET e parâmetros do ZARC/Embrapa. A seleção deverá considerar a espécie do café, a origem da informação, as unidades de medida, o contexto regional e a adequação do dado ao objetivo de classificação.

O INMET disponibiliza dados observados por estações meteorológicas automáticas e séries históricas por meio de seus serviços de dados meteorológicos.

Esses dados podem apoiar a contextualização das condições climáticas e a construção de conjuntos históricos, mas não substituem as leituras locais de umidade do solo realizadas pelo protótipo (INMET, s.d.).

A base EcoCrop disponibiliza descritores ambientais de espécies vegetais, incluindo faixas de temperatura e precipitação. A FAO informa que a base foi descontinuada como serviço independente por volta de 2015, permanecendo acessível por meio da plataforma Global Agro-Ecological Zones. Essa condição deverá ser considerada na documentação da fonte e na avaliação da atualidade dos registros utilizados (FAO, s.d.).

Cada fonte incorporada deverá ser registrada no repositório, com identificação, endereço, data de acesso, variáveis aproveitadas e eventuais transformações. Dados simulados deverão ser identificados explicitamente como simulados, sem serem apresentados como medições reais de lavouras.

### 7.3 Coleta e tratamento dos dados

A etapa de coleta consistirá na montagem do circuito com Arduino, sensor de umidade do solo e DHT11. O programa embarcado realizará leituras em intervalos definidos pela equipe e transmitirá os valores por comunicação serial. A aplicação Python receberá os dados por PySerial, validará o formato da mensagem e registrará as medições acompanhadas de data e hora.

O tratamento incluirá verificação de integridade, remoção ou sinalização de registros inválidos, padronização de unidades e análise de valores extremos. Os critérios para descartar ou manter uma leitura deverão ser documentados para que o processo seja reproduzível. A calibração do sensor de umidade do solo será tratada como etapa essencial, pois a leitura bruta não representa automaticamente um percentual universal de água disponível para qualquer tipo de solo.

Após o tratamento, os dados serão armazenados no SQLite3. O banco deverá permitir recuperar o histórico e gerar conjuntos de dados para treinamento, teste e análise. A estrutura inicial poderá conter uma tabela de medições, com identificador, instante de coleta, umidade do solo, temperatura, umidade relativa, origem do registro e situação de validade.

### 7.4 Treinamento e avaliação do modelo

O conjunto de dados será organizado em atributos de entrada e variável-alvo. Os atributos corresponderão às leituras de umidade do solo, temperatura e umidade relativa do ar. A variável-alvo será a classe de condição da lavoura: Verde, Amarelo ou Vermelho. Os critérios de rotulagem serão construídos a partir das referências selecionadas e documentados para permitir a interpretação dos resultados.

A divisão inicial será de 80% das amostras para treinamento e 20% para teste, utilizando train_test_split, conforme a proposta técnica original. O modelo será treinado com Scikit-Learn. A equipe deverá registrar o algoritmo efetivamente selecionado, seus parâmetros, a versão das bibliotecas e a estratégia de divisão dos dados. Caso sejam comparados diferentes classificadores, a escolha final deverá considerar as métricas e a interpretabilidade, além do desempenho global.

A avaliação utilizará matriz de confusão, precisão, revocação, F1-Score e acurácia. Recomenda-se apresentar as métricas por classe e a média macro, especialmente se houver desequilíbrio entre as categorias. A análise deverá destacar os falsos negativos da classe crítica, pois a ausência de um alerta em uma condição que deveria ser sinalizada pode representar risco maior do que uma classificação conservadora.

A equipe também deverá estabelecer uma linha de base simples, como um classificador que sempre prevê a classe majoritária ou uma regra de referência documentada. Essa comparação ajuda a verificar se o modelo oferece ganho real em relação a uma estratégia elementar. O resultado do eval será documentado no GitHub, incluindo conjunto de teste, métricas, matriz de confusão e limitações.

### 7.5 Desenvolvimento da interface

A interface será projetada para apresentar a condição atual da lavoura de maneira direta. O elemento central será o semáforo virtual, com três estados visuais acompanhados de rótulos textuais: “Ideal”, “Atenção” e “Ação crítica”. A cor não deverá ser o único meio de comunicação, pois usuários com daltonismo ou dificuldades de percepção cromática também precisam compreender o resultado. Por isso, cada estado será acompanhado de texto e, quando possível, de um ícone ou mensagem curta.

A tela deverá apresentar também o momento da última atualização e um aviso quando os dados estiverem indisponíveis ou desatualizados. A linguagem será simples, evitando termos técnicos sem explicação. A organização visual deverá priorizar legibilidade, contraste e poucos elementos simultâneos, de acordo com o público-alvo definido.

### 7.6 Testes de software

Os testes automatizados serão aplicados às partes críticas do sistema. Os testes unitários deverão verificar funções de validação, conversão e tratamento de leituras, preparação dos atributos e interpretação da saída do classificador. Os testes de integração deverão verificar a comunicação entre os módulos Python, o armazenamento no SQLite e a chamada ao modelo.

Também serão realizados testes de ponta a ponta, verificando o fluxo completo: sensor realiza a leitura; Arduino transmite os dados; Python recebe e processa; o banco armazena; o modelo classifica; e a interface atualiza o estado do semáforo. Serão simuladas situações de falha, como desconexão do sensor, mensagem serial incompleta, valor fora do intervalo esperado e ausência de dados recentes.

Os resultados dos testes deverão ser registrados, incluindo cenário, resultado esperado, resultado obtido e situação de aprovação. A execução dos testes deverá ser repetível e integrada ao repositório do grupo.

## 8 DESCRIÇÃO DA SOLUÇÃO PROPOSTA

### 8.1 Arquitetura geral

A arquitetura do AgroAnálise será organizada em três camadas integradas: aquisição física, processamento e armazenamento, e inteligência artificial com apresentação dos resultados. Essa separação permite identificar a responsabilidade de cada componente e facilita a realização de testes isolados e integrados.

| Camada | Componentes | Responsabilidade |
|---|---|---|
| Aquisição de dados | Arduino, sensor de umidade do solo e DHT11 | Realizar leituras das variáveis ambientais e transmitir os dados por comunicação serial. |
| Processamento e armazenamento | Python, PySerial, Pandas, NumPy e SQLite3 | Receber, validar, tratar, organizar e armazenar as |

| | | |
|---|---|---|
| | | medições. |
| Classificação e apresentação | Scikit-Learn e interface do semáforo virtual | Classificar as condições monitoradas e apresentar o resultado de forma simplificada. |

## 8.2 Fluxo operacional

11. O sensor de umidade do solo mede a condição hídrica no ponto em que está instalado.
12. O DHT11 registra a temperatura e a umidade relativa do ar.
13. O Arduino reúne as leituras e as envia ao computador por comunicação serial.
14. A aplicação Python recebe os dados por meio do PySerial e verifica se a mensagem está completa e dentro dos critérios de validade.
15. As leituras válidas são tratadas com apoio de Pandas e NumPy e registradas no banco SQLite3.
16. Os atributos necessários são encaminhados ao modelo de classificação treinado com Scikit-Learn.
17. O modelo retorna uma das três classes definidas no projeto.
18. A interface atualiza o semáforo virtual e apresenta a última atualização, a classificação e uma mensagem explicativa.

## 8.3 Semáforo virtual

| Estado | Significado no sistema | Comportamento esperado |
|---|---|---|
| Verde — Ideal | As variáveis avaliadas estão dentro da faixa definida como adequada para os critérios adotados. | Informar que, segundo a leitura e os parâmetros configurados, não foi identificado alerta no momento. |
| Amarelo — Atenção | Uma ou mais variáveis se aproximam de condições que exigem acompanhamento. | Orientar o produtor a observar a lavoura e acompanhar novas leituras. |
| Vermelho — Ação crítica | As variáveis indicam condição classificada como crítica segundo os critérios do modelo. | Recomendar verificação da área e avaliação da necessidade de intervenção, sem acionar automaticamente a irrigação. |

Os significados das classes deverão ser traduzidos em regras operacionais documentadas. Os limites numéricos não serão definidos arbitrariamente: deverão ser

estabelecidos após o levantamento de referências, a consideração das diferenças entre Arábica e Conilon e, sempre que possível, a validação com orientação agronômica. Se o protótipo não possuir informação suficiente para classificar uma leitura, deverá apresentar um estado de indisponibilidade, e não presumir condição ideal.

## 9 COMUNIDADE IMPACTADA E INDICADORES

A comunidade diretamente considerada pelo projeto é formada por agricultores familiares que cultivam café e apresentam baixo ou nenhum letramento digital. A solução também pode beneficiar, de maneira indireta, técnicos e agentes de assistência rural que apoiam esses produtores, uma vez que a organização das leituras pode facilitar a discussão sobre condições ambientais e manejo.

A caracterização socioeconômica detalhada da comunidade ainda deverá ser aprofundada por meio de fontes públicas, como IBGE, dados oficiais da agricultura e publicações técnicas. O relatório inicial não apresenta números específicos sobre quantidade de propriedades, perfil etário, renda ou volume de produção do público a ser atendido. Portanto, tais informações não serão presumidas e deverão ser acrescentadas somente após levantamento documental.

### 9.1 Indicadores de impacto

| Dimensão | Indicador | Forma de acompanhamento |
|---|---|---|
| Tecnológica e social | Taxa de adoção autônoma | Número de propriedades ou usuários que conseguem operar o sistema sem suporte técnico contínuo, em relação ao total de participantes avaliados. |
| Econômica e ambiental | Estimativa percentual de redução do desperdício de água de irrigação | Comparação do volume de água utilizado em períodos ou condições comparáveis, registrando método, intervalo e limitações da estimativa. |
| Produtiva | Redução da taxa de perdas associadas à identificação tardia de estresse hídrico ou térmico | Acompanhamento de ocorrências registradas e comparação com uma linha de base, quando houver dados suficientes. |
| Operacional | Número de leituras válidas e disponibilidade do sistema | Proporção de leituras recebidas e processadas corretamente em relação às tentativas de coleta. |
| Usabilidade | Percepção de clareza e facilidade de uso | Questionário ou entrevista breve com usuários durante testes de |

| | | |
|---|---|---|
| | | utilização. |

Os indicadores de impacto deverão ser medidos com procedimentos definidos antes da coleta. Para a taxa de adoção autônoma, será necessário estabelecer o que caracteriza uma operação independente e por quanto tempo o usuário deverá utilizar o sistema sem auxílio. Para a eficiência hídrica, será necessário obter registros comparáveis de consumo de água, pois a simples emissão de alertas não comprova economia. Para o indicador produtivo, a equipe deverá reconhecer que a perda de safra depende de múltiplos fatores e que a contribuição específica do sistema não pode ser isolada sem acompanhamento adequado.

Na etapa acadêmica, caso não seja possível realizar testes em propriedades reais, os indicadores poderão ser apresentados como plano de mensuração e avaliados preliminarmente em ambiente controlado ou com usuários simulados. Nesse caso, os resultados deverão ser identificados como testes de protótipo, sem generalização para toda a comunidade agrícola.

## 10 IA RESPONSÁVEL, RISCOS E LIMITAÇÕES

### 10.1 Privacidade e proteção de dados

O sistema foi concebido para coletar principalmente dados ambientais e agronômicos, não sendo necessário, em sua operação básica, armazenar dados pessoais dos agricultores. Caso sejam coletadas informações de identificação durante testes de usabilidade ou acompanhamento da adoção, a equipe deverá informar a finalidade, limitar a coleta ao mínimo necessário e restringir o acesso aos registros. A Lei nº 13.709/2018 (Lei Geral de Proteção de Dados Pessoais — LGPD) estabelece princípios como finalidade, adequação, necessidade, transparência, segurança e prevenção, que deverão orientar eventual tratamento de dados pessoais (BRASIL, 2018).

Sempre que possível, os resultados de testes deverão ser registrados de forma agregada ou anonimizada. O repositório público não deverá conter dados pessoais, credenciais, tokens, senhas ou informações que permitam identificar participantes sem necessidade.

### 10.2 Segurança e confiabilidade

A segurança deverá contemplar a integridade dos dados transmitidos e armazenados, o controle de acesso ao equipamento e a proteção do repositório. A aplicação deverá validar entradas recebidas pela porta serial, rejeitar mensagens malformadas e registrar falhas sem interromper indevidamente o processamento. Caso uma versão futura ofereça acesso remoto, será necessário acrescentar mecanismos de autenticação, autorização e comunicação protegida.

### 10.3 Ética, transparência e limitações

O sistema deverá informar que a classificação é uma indicação automatizada baseada nas variáveis disponíveis e nos parâmetros adotados. Não deverá ser apresentada como diagnóstico definitivo da saúde da planta ou como recomendação agronômica individualizada. A decisão de irrigar ou executar qualquer manejo deverá permanecer com o produtor, considerando observação da lavoura e orientação técnica.

Entre as limitações previstas estão a quantidade reduzida de sensores, a influência do tipo de solo nas leituras, a precisão do DHT11, a representatividade dos dados históricos ou simulados, a diferença entre as espécies de café e a ausência de variáveis como precipitação local, radiação solar, estágio fenológico, textura do solo e profundidade efetiva das raízes. Essas limitações deverão constar da documentação e ser consideradas ao interpretar as métricas do modelo.

### 10.4 Custos e sustentabilidade

A proposta utiliza componentes de prototipagem e ferramentas de software que permitem desenvolver uma prova de conceito com baixo custo. O grupo deverá registrar os custos efetivamente incorridos com sensores, microcontrolador, cabos, alimentação elétrica e demais componentes. Também deverá considerar o consumo energético e a durabilidade dos equipamentos, evitando afirmar sustentabilidade apenas pela utilização de software livre ou de baixo custo.

## 11 PLANO DE TRABALHO

O cronograma foi organizado de acordo com os três checkpoints definidos no edital do Projeto Integrador IV. As atividades abaixo detalham o planejamento técnico apresentado no relatório inicial e relacionam cada etapa aos artefatos que deverão ser produzidos.

| Checkpoint | Atividades principais | Artefatos e evidências |
|---|---|---|
| C1 — Relatório e levantamento | Definição do problema, público-alvo, regras de negócio, arquitetura, indicadores, levantamento bibliográfico e parâmetros de referência para café. Organização inicial do GitHub. | Relatório de escopo; repositório inicial; fontes agronômicas identificadas; plano de trabalho e indicadores previstos. |
| C2 — Protótipo, IoT e eval inicial | Montagem dos sensores no Arduino; comunicação via PySerial; estruturação do SQLite; geração e limpeza do conjunto de dados; treinamento inicial do classificador. | Protótipo físico de coleta; script Python; banco de dados; dataset documentado; modelo inicial; métricas e vídeo demonstrativo. |
| C3 — MVP, interface e testes finais | Desenvolvimento do semáforo virtual; integração completa; testes unitários, integração e ponta a ponta; documentação e publicação do MVP. | Aplicação funcional; testes e resultados do eval; documentação; código-fonte; vídeo no YouTube; URL pública de deploy, quando aplicável; análise de impacto. |

Conforme o edital, os prazos dos checkpoints são: C1 em 18 de setembro de 2026; C2 em 30 de outubro de 2026; e C3 em 4 de dezembro de 2026. O grupo deverá manter o repositório atualizado a cada entrega e registrar as contribuições e decisões técnicas ao longo do desenvolvimento.

## 12 RESULTADOS ESPERADOS

Espera-se que o AgroAnálise resulte em um protótipo integrado capaz de realizar a leitura de umidade do solo, temperatura e umidade relativa do ar, transmitir os dados a uma aplicação Python, armazenar o histórico e produzir uma classificação automatizada em três estados. A integração deverá ser demonstrada por meio de testes que percorram o caminho completo entre o sensor e a interface.

No aspecto tecnológico, espera-se comprovar a viabilidade de uma arquitetura de baixo custo que reúna hardware, comunicação serial, processamento de dados, banco relacional e aprendizado de máquina. A avaliação do classificador deverá

apresentar métricas e análise dos erros, permitindo identificar em quais condições o modelo apresenta maior confiabilidade e quais limitações permanecem.

No aspecto de usabilidade, espera-se que a representação em semáforo facilite a compreensão das condições monitoradas, especialmente para pessoas com pouca familiaridade com gráficos e indicadores técnicos. Essa expectativa deverá ser verificada por meio de testes com usuários ou participantes simulados, utilizando tarefas objetivas e instrumentos de coleta de percepção.

No aspecto social e ambiental, espera-se estabelecer uma base para avaliar a adoção autônoma da tecnologia e sua possível contribuição para o uso mais criterioso da água e para a identificação antecipada de condições ambientais desfavoráveis. Tais benefícios são hipóteses de impacto a serem investigadas, e não resultados já comprovados pelo desenvolvimento do protótipo.

Como resultado acadêmico, o grupo deverá entregar documentação técnica e científica, repositório organizado, testes automatizados, avaliação do modelo, demonstração em vídeo e, no checkpoint final, uma versão mínima viável publicada em ambiente acessível, de acordo com as exigências do edital.

## 13 CONSIDERAÇÕES FINAIS

O AgroAnálise propõe uma aplicação de IoT e Machine Learning orientada a um desafio concreto: ampliar o acesso de agricultores familiares a informações ambientais relevantes para o acompanhamento de plantações de café. A proposta combina a coleta automatizada de variáveis, o tratamento computacional dos dados e a classificação em uma interface visual simples, buscando aproximar recursos tecnológicos da realidade de usuários com baixo letramento digital.

A escolha do café como cultura inicial permite delimitar o problema e direcionar o levantamento de parâmetros para Arábica e Conilon. A arquitetura prevista, baseada em Arduino, sensores, Python, PySerial, Pandas, NumPy, SQLite3 e Scikit-Learn, oferece uma estrutura viável para a construção de um protótipo acadêmico. Entretanto, a confiabilidade da solução dependerá da calibração dos sensores, da qualidade e representatividade dos dados, da definição criteriosa das classes e da avaliação transparente do modelo.

O projeto também reconhece que uma classificação automatizada não substitui o conhecimento agronômico nem deve determinar, isoladamente, decisões de manejo. Por esse motivo, a interface deverá comunicar os resultados como alertas de apoio, enquanto a documentação apresentará as limitações técnicas e os riscos de interpretação. A avaliação do impacto deverá utilizar indicadores mensuráveis, evitando atribuir ao sistema ganhos produtivos ou ambientais que ainda não tenham sido demonstrados.

Conclui-se que o AgroAnálise possui potencial para integrar conhecimentos de hardware, desenvolvimento de software, banco de dados, inteligência artificial e responsabilidade tecnológica em uma solução de caráter extensionista. O avanço do projeto dependerá da execução organizada dos checkpoints, da validação técnica e da atenção permanente à experiência do público-alvo. Dessa forma, o trabalho busca não apenas demonstrar o funcionamento de tecnologias emergentes, mas também investigar como elas podem ser aplicadas de maneira acessível e responsável em um contexto real.

## REFERÊNCIAS


BONOMO, D. Z.; BONOMO, R.; PEZZOPANE, J. R. M.; SOUZA, J. M. de. Alternativas de manejo de água de irrigação em cultivos de Conilon. 2014. Disponível em: https://www.embrapa.br/en/busca-de-publicacoes/-/publicacao/997903/alternativas-de-manejo-de-agua-de-irrigacao-em-cultivos-de-conilon. Acesso em: 26 out. 2026.

BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709compilado.htm. Acesso em: 26 out. 2026.

BRASIL. Ministério da Agricultura e Pecuária. Programa Nacional de Zoneamento Agrícola de Risco Climático (ZARC): Café. Brasília, DF, 2024. Disponível em: https://www.gov.br/agricultura/pt-br/assuntos/riscos-seguro/programa-nacional-de-zoneamento-agricola-de-risco-climatico/notas-tecnicas-air/cafe_arabica. Acesso em: 26 out. 2026.

FAO — FOOD AND AGRICULTURE ORGANIZATION OF THE UNITED NATIONS. ECOCROP: database of crop constraints and characteristics. Rome: FAO, [s.d.]. Disponível em: https://www.fao.org/geospatial/data-and-tools/data-portals/ecocrop/. Acesso em: 26 out. 2026.

FAO — FOOD AND AGRICULTURE ORGANIZATION OF THE UNITED NATIONS. EcoCrop data sheet: Coffea arabica. [s.d.]. Disponível em:

https://ecocrop.apps.fao.org/ecocrop/srv/en/dataSheet?id=749. Acesso em: 26 out. 2026.

INMET — INSTITUTO NACIONAL DE METEOROLOGIA. Estações automáticas. Brasília, DF: Ministério da Agricultura e Pecuária, [s.d.]. Disponível em: https://portal.inmet.gov.br/servicos/esta%C3%A7%C3%B5es-autom%C3%A1ticas. Acesso em: 26 out. 2026.

SCIKIT-LEARN DEVELOPERS. Metrics and scoring: quantifying the quality of predictions. Scikit-learn documentation, [s.d.]. Disponível em: https://scikit-learn.org/stable/modules/model_evaluation.html. Acesso em: 26 out. 2026.